

Poniżej masz gotową, jednostronicową specyfikację, którą możesz wkleić jako prompt.

Specyfikacja MVP: analiza skuteczności modeli dla arbitrażu Fixing1 vs Fixing2

Chcę zbudować pierwszy MVP do oceny skuteczności modeli prognostycznych pod kątem spekulacji/arbitrażu między Fixing1 i Fixing2 na rynku energii.

Cel

Celem nie jest klasyczna ocena błędu ceny, tylko ocena, który model najlepiej przewiduje **kierunek zmiany ceny między Fixing1 a Fixing2** dla kolejnego dnia dostawy.

Interesuje mnie odpowiedź:

Który model w ostatnich X dniach najlepiej wskazywał, czy należy zająć pozycję LONG albo SHORT względem spreadu Fixing2 – Fixing1?

Dane wejściowe

Wykorzystaj dane z istniejącej bazy DuckDB:

/home/ubuntu/db/forecast_db.duckdb

Zakładane tabele:

- forecast_prices — prognozy modeli
- runs — metadata uruchomień modeli
- market_features_raw albo tabela z rzeczywistymi Fixing1/Fixing2

Struktura prognoz zawiera m.in.:

- run_id
- ts
- model
- price_pln_mwh
- fixing_type
- delivery_date
- H

Tabela wynikowa powinna porównywać prognozę ceny Fixing2 z rzeczywistym Fixing1 i rzeczywistym Fixing2.

Logika sygnału

Dla każdej daty dostawy, godziny i modelu:

$\text{forecast_spread} = \text{forecast_F2} - \text{actual_F1}$

$\text{actual_spread} = \text{actual_F2} - \text{actual_F1}$

Sygnal modelu:

LONG jeżeli $\text{forecast_spread} > 0$

SHORT jeżeli $\text{forecast_spread} < 0$

FLAT jeżeli $\text{forecast_spread} = 0$

Rzeczywisty kierunek rynku:

LONG jeżeli $\text{actual_spread} > 0$

SHORT jeżeli $\text{actual_spread} < 0$

FLAT jeżeli $\text{actual_spread} = 0$

Trafienie:

hit = 1, jeżeli $\text{signal} == \text{actual_direction}$

hit = 0, jeżeli $\text{signal} != \text{actual_direction}$

Symulowany PnL dla 1 MW:

position = +1 dla LONG

position = -1 dla SHORT

position = 0 dla FLAT

$\text{pnl} = \text{position} * \text{actual_spread}$

Tabela analityczna MVP

Utwórz dataframe df_perf z kolumnami:

delivery_date

H

model

forecast_F2

actual_F1

actual_F2

forecast_spread

actual_spread

signal

actual_direction

hit

pnl

abs_spread

gdzie:

abs_spread = abs(actual_spread)

Zakres analizy

Domyślnie analizuj ostatnie 7 dni dostępnych danych, ale kod powinien pozwalać łatwo zmienić parametr:

LOOKBACK_DAYS = 7

Dodatkowo przygotuj możliwość testowania:

LOOKBACK_DAYS = 3

LOOKBACK_DAYS = 5

LOOKBACK_DAYS = 7

LOOKBACK_DAYS = 14

Wyniki do pokazania

Na końcu skrypt ma pokazać ranking modeli:

model

liczba_obserwacji

hit_ratio

total_pnl

avg_pnl

avg_abs_spread

Sortowanie domyślne:

1. najwyższy total_pnl
2. najwyższy hit_ratio

Dodatkowo pokaż ranking godzinowy:

model

H

hit_ratio

total_pnl

liczba_obserwacji

Interpretacja

Wynik ma pomóc odpowiedzieć:

- który model najlepiej działa kierunkowo,
- który model daje najwyższy symulowany PnL,
- czy model dobrze działa tylko w wybranych godzinach,
- czy ostatnie 7 dni wskazują na zmianę skuteczności modeli.

Wymagania techniczne

Kod ma być napisany w Pythonie, z użyciem:

duckdb

pandas

numpy

Kod ma:

- połączyć się z DuckDB,
- pobrać potrzebne dane,
- zbudować df_perf,
- policzyć ranking modeli,
- policzyć ranking godzinowy,
- wyświetlić najnowszą analizowaną datę,
- wyświetlić zakres dat,
- pokazać liczbę obserwacji per model,
- zamknąć połączenie DuckDB.

Styl logów:

[INFO] Start analizy

[INFO] Zakres dat: ...

[OK] Dane pobrane

[OK] Tabela df_perf utworzona

[OK] Ranking modeli policzony

[DONE]

Ważne założenie

To jest MVP tradingowe. Priorytetem jest **trafność kierunku i PnL**, a nie klasyczny błąd prognozy ceny.

PRzykładowa tablica

H Best model Hit Ratio 7d PnL 7d Signal

1	XGBoost	71%	+420	LONG
2	RF	68%	+310	SHORT
3	ARIMA	63%	+180	LONG
...	...	...	...	...
24	XGBoost	74%	+510	LONG